教学设计方案 S09:Milvus 向量检索与 RAG 重排

学习领域 LF4 | 第 9 周 | 授课教师版 | 180 分钟

1. 教学目标(布鲁姆分层)

- [解] 解释'召回-重排'两段式与 embedding 的语义检索原理
- [应] 执行 KB 在线评测并解读 Recall/MRR/nDCG
- [析] 诊断一次'检索不准'该怪召回还是怪重排

2. 教学重难点

- 重点:诊断一次'检索不准'该怪召回还是怪重排
- 难点:执行 KB 在线评测并解读 Recall/MRR/nDCG
- 突破策略:情境导入(真实事故/需求)→知识建构精讲→真仓实训→检查互证→费曼外化

3. 教学准备

- 教学集群可用性预检(教师课前 30min);任务单打印/电子发牌;
- 情境素材核对:以 PLPP 最新 PROGRESS 阶段刷新本课情境(同步脚本拉取 project-references/)。

4. 180 分钟流程

环节	时长	教师动作	学生活动	观测点
A 情境导入	20'	讲情境、发任务单	领会工单、明确目标	能复述本课目标
B 计划	10'	巡视,不代拆	组内拆解分工	计划可执行
C 决策	5'	把关安全红线	30 秒方案陈述	红线重申到位
D 理论精讲	35'	按'知识建构要点'爬梯,层层提问	答+记笔记+追问	每层有应答
E 实施	70'	双师巡回,只提问不代写	真仓实操、记工单	步骤推进与证据留存
F 检查	15'	抽查	检查员勾验+互查	清单全过

环节	时长	教师动作	学生活动	观测点
G 评价+费曼	25'	评分点回收; 费曼只提问	费曼员上台	外行能懂

5. 理论精讲提纲(35min)

1) 向量检索原理

- 文本→embedding 向量;语义相近=向量距离近(余弦)
- Milvus=向量数据库:edu_resources 集合,360 知识点灌库

2) 召回-重排两段式

- 召回(vector-reranker /internal/search):宽召回 topK
- 重排(reranker 精排):相关性重打分——宽进严出
- 降级链:reranker 挂→退回纯召回(降级安全)

3) 如何量化'准'

- 在线标注集 45 条;/internal/eval 三指标
- 基线:Recall 1.0 / MRR 0.933 / nDCG 0.951
- Recall=该找到的找到了吗;MRR=对的排多前;nDCG=整体排序质量

6. 实训指导(70min)

1. **1. 体验检索**:POST reranker /internal/search, query='RSA 教学案例', 看返回
2. **2. 跑评测**:执行 /internal/eval,记录三指标与基线对比
3. **3. 诊断实验**:换 3 个偏题 query,观察指标波动,定位是召回弱还是排序弱
4. **4. 报告**:产出 1 页《检索质量报告》:指标+诊断+1 条改进建议

7. 布鲁姆提问设计(课堂穿插)

- [解] 为什么…而不是…?(解释'召回-重排'两段式与 embedding …)
- [应] 现场演示…(执行 KB 在线评测并解读 Recall/MRR…)
- [析] 如果…坏了,断在哪一跳?(诊断一次'检索不准'该怪召回还是怪重排…)

8. 费曼讲题与引导

讲题:用'图书馆先按主题拉一车书(召回),管理员再挑最相关的三本放你桌上(重排)'讲两段式。 追问链:还有吗?→换个说法?→如果外行问…你怎么答?→一句话压缩?

9. 评价与作业

评分点:指标解读准确性(40%)+诊断逻辑(40%)+报告(20%) 作业:

- 费曼卡#9:两段式 200 字+手绘图
- 检索质量报告 1 页

10. 板书设计

左板:本课目标(三层) | 中板:核心流程图(随精讲生长) | 右板:实训进度墙(各组勾验状态)