教学设计方案 S10:LLM 编排与智能体骨架

学习领域 LF5 | 第 10 周 | 授课教师版 | 180 分钟

1. 教学目标(布鲁姆分层)

- [解] 解释 agent-service 的工具调用机制与 fallback 链
- [应] 完成 LLM 通道配置切换(ollama 直连)并跑通对话
- [析] 复盘 litellm 基座事故:何时该绕行而非硬修

2. 教学重难点

- 重点:复盘 litellm 基座事故:何时该绕行而非硬修
- 难点:完成 LLM 通道配置切换(ollama 直连)并跑通对话
- 突破策略:情境导入(真实事故/需求)→知识建构精讲→真仓实训→检查互证→费曼外化

3. 教学准备

- 教学集群可用性预检(教师课前 30min);任务单打印/电子发牌;
- 情境素材核对:以 PLPP 最新 PROGRESS 阶段刷新本课情境(同步脚本拉取 project-references/)。

4. 180 分钟流程

环节	时长	教师动作	学生活动	观测点
A 情境导入	20'	讲情境、发任务单	领会工单、明确目标	能复述本课目标
B 计划	10'	巡视,不代拆	组内拆解分工	计划可执行
C 决策	5'	把关安全红线	30 秒方案陈述	红线重申到位
D 理论精讲	35'	按'知识建构要点'爬梯,层层提问	答+记笔记+追问	每层有应答
E 实施	70'	双师巡回,只提问不代写	真仓实操、记工单	步骤推进与证据留存
F 检查	15'	抽查	检查员勾验+互查	清单全过

环节	时长	教师动作	学生活动	观测点
G 评价+费曼	25'	评分点回收; 费曼只提问	费曼员上台	外行能懂

5. 理论精讲提纲(35min)

1) LLM 服务链

- 应用层(agent/ai)→LLM 网关(litellm,多供应商路由)→推理(ollama qwen2.5:14b)
- 配置在 configmap-secret.yaml:LLM_BASE_URL/LLM_MODEL

2) fallback 与降级

- config.build_llm(with_fallbacks):主模型挂→备用模型顶上
- 韧性视角:LLM 也是'外部依赖',同样要超时/重试/降级

3) 真实事故:litellm DB

- DATABASE_URL 注入→Prisma CLI 工具链 600s 超时→CrashLoop→回滚
- 决策依据:主链不依赖 litellm(直连 ollama)→先绕行,基座问题挂账
- 诚实挂起≠放弃:记录根因+后续方案(pre-migration Job/官方镜像)

4) 成本意识(LCO 三层缓存)

- L1 精确缓存/L2 语义缓存/L3 知识图谱——省 40%+ 成本
- 缓存命中必须透传元数据(cache_hit/cache_layer)供监控

6. 实训指导(70min)

1. **1. 看配置**:读 configmap-secret.yaml 的 LLM_* 三键,画通道图
2. **2. 切通道**:(教学租户)LLM_BASE_URL 指向 ollama-worker,重启 agent pod
3. **3. 跑对话**:经 agent 助手发起一次问答,确认响应与模型名
4. **4. 复盘卡**:litellm 事故卡:现象/根因/决策/挂账方案四栏

7. 布鲁姆提问设计(课堂穿插)

- [解] 为什么…而不是…?(解释 agent-service 的工具调用机制…)
- [应] 现场演示…(完成 LLM 通道配置切换(ollama 直连)…)
- [析] 如果…坏了,断在哪一跳?(复盘 litellm 基座事故:何时该绕行而非硬…)

8. 费曼讲题与引导

讲题:给外行讲'大模型网关'像'旅行社':你只说要去哪,它帮你选航班,航班取消还能改签(fallback)。 追问链:还有吗?→换个说法?→如果外行问…你怎么答?→一句话压缩?

9. 评价与作业

评分点:切换实操(40%)+决策复盘(40%)+类比(20%) 作业:

- 费曼卡#10:网关类比 200 字
- 事故卡归档+通道图拍照

10. 板书设计

左板:本课目标(三层) | 中板:核心流程图(随精讲生长) | 右板:实训进度墙(各组勾验状态)