学习任务单 S09:Milvus 向量检索与 RAG 重排

学习领域 LF4 | 第 9 周 | 4 课时(180min)| 双元制六步法+费曼讲台

布鲁姆目标(本课你要达到)

- **[解]** 解释'召回-重排'两段式与 embedding 的语义检索原理
- **[应]** 执行 KB 在线评测并解读 Recall/MRR/nDCG
- **[析]** 诊断一次'检索不准'该怪召回还是怪重排

情境导入(资讯)

企业情境:教研老师投诉'搜 RSA 教学案例,返回的全是无关内容'。你要用评测数据回答:系统到底准不准?不准在哪一段?

上节回顾

图谱 STATS 对齐抽查;M2 数据报告讲评。

计划与决策

1. 工单员领单,组内宣读目标与交付物;
2. 拆解实训步骤,分配操作员/检查员;
3. 向教师陈述 30 秒方案,**重申安全红线**(禁 L2/L3 越权操作)。

知识建构精讲要点(理论 35min,教师主持)

向量检索原理

- 文本→embedding 向量;语义相近=向量距离近(余弦)
- Milvus=向量数据库:edu_resources 集合,360 知识点灌库

召回-重排两段式

- 召回(vector-reranker /internal/search):宽召回 topK
- 重排(reranker 精排):相关性重打分——宽进严出
- 降级链:reranker 挂→退回纯召回(降级安全)

如何量化'准'

- 在线标注集 45 条;/internal/eval 三指标
- 基线:Recall 1.0 / MRR 0.933 / nDCG 0.951
- Recall=该找到的找到了吗;MRR=对的排多前;nDCG=整体排序质量

实训实施(70min,双师巡回)

1. **1. 体验检索** — POST reranker /internal/search, query='RSA 教学案例', 看返回
2. **2. 跑评测** — 执行 /internal/eval,记录三指标与基线对比
3. **3. 诊断实验** — 换 3 个偏题 query,观察指标波动,定位是召回弱还是排序弱
4. **4. 报告** — 产出 1 页《检索质量报告》:指标+诊断+1 条改进建议

检查清单(15min,检查员主持·互查组复核)

- □ [应] 评测命令与指标输出留证
- □ [析] 能用指标变化定位问题段(召回/重排)
- □ [解] 两段式流程图过关

费曼讲台(15min)

讲题:用'图书馆先按主题拉一车书(召回),管理员再挑最相关的三本放你桌上(重排)'讲两段式。 规程:白纸讲授 6min(不看笔记)→同伴追问 4min(卡壳即回炉)→类比压缩 3min。未过检查清单的小组不得上台。

课后作业

- 费曼卡#9:两段式 200 字+手绘图
- 检索质量报告 1 页

评分点

指标解读准确性(40%)+诊断逻辑(40%)+报告(20%)

证据纪律:所有'完成'必须附命令输出/截图;如实记录失败与返工(诚实=加分)。