学习任务单 S10:LLM 编排与智能体骨架

学习领域 LF5 | 第 10 周 | 4 课时(180min)| 双元制六步法+费曼讲台

布鲁姆目标(本课你要达到)

- **[解]** 解释 agent-service 的工具调用机制与 fallback 链
- **[应]** 完成 LLM 通道配置切换(ollama 直连)并跑通对话
- **[析]** 复盘 litellm 基座事故:何时该绕行而非硬修

情境导入(资讯)

企业情境:大模型网关 litellm 的数据库迁移卡死 600 秒,pod 反复崩溃。全组都在等它好——但业务等不起。真实决策:业务改走 ollama 直连,基座问题诚实挂起。今天复盘这个'绕行决策'。

上节回顾

检索报告快评;费曼卡抽查。

计划与决策

1. 工单员领单,组内宣读目标与交付物;
2. 拆解实训步骤,分配操作员/检查员;
3. 向教师陈述 30 秒方案,重申安全红线(禁 L2/L3 越权操作)。

知识建构精讲要点(理论 35min,教师主持)

LLM 服务链

- 应用层(agent/ai)→LLM 网关(litellm,多供应商路由)→推理(ollama qwen2.5:14b)
- 配置在 configmap-secret.yaml:LLM_BASE_URL/LLM_MODEL

fallback 与降级

- config.build_llm(with_fallbacks):主模型挂→备用模型顶上
- 韧性视角:LLM 也是'外部依赖',同样要超时/重试/降级

真实事故:litellm DB

- DATABASE_URL 注入→Prisma CLI 工具链 600s 超时→CrashLoop→回滚
- 决策依据:主链不依赖 litellm(直连 ollama)→先绕行,基座问题挂账
- 诚实挂起≠放弃:记录根因+后续方案(pre-migration Job/官方镜像)

成本意识(LCO 三层缓存)

- L1 精确缓存/L2 语义缓存/L3 知识图谱——省 40%+ 成本
- 缓存命中必须透传元数据(cache_hit/cache_layer)供监控

实训实施(70min,双师巡回)

1. **1. 看配置** — 读 configmap-secret.yaml 的 LLM_* 三键,画通道图
2. **2. 切通道** — (教学租户)LLM_BASE_URL 指向 ollama-worker,重启 agent pod
3. **3. 跑对话** — 经 agent 助手发起一次问答,确认响应与模型名
4. **4. 复盘卡** — litellm 事故卡:现象/根因/决策/挂账方案四栏

检查清单(15min,检查员主持·互查组复核)

- □ [应] 切换后对话成功证据(响应截图)
- □ [析] 能说清'绕行 vs 硬修'的判断依据(爆炸半径/主链影响)
- □ [解] fallback 链机制口头过关

费曼讲台(15min)

讲题:给外行讲'大模型网关'像'旅行社':你只说要去哪,它帮你选航班,航班取消还能改签(fallback)。 规程:白纸讲授 6min(不看笔记)→同伴追问 4min(卡壳即回炉)→类比压缩 3min。未过检查清单的小组不得上台。

课后作业

- 费曼卡#10:网关类比 200 字
- 事故卡归档+通道图拍照

评分点

切换实操(40%)+决策复盘(40%)+类比(20%)

证据纪律:所有'完成'必须附命令输出/截图;如实记录失败与返工(诚实=加分)。